EL NÚMERO TE MIENTE. LA NUBE NO.

Cuatro nubes de puntos distintas pueden tener el mismo promedio y la misma correlación. Cómo leer lo que el coeficiente esconde.

ÍNDICE

1. El cuarteto de Anscombe — cuatro historias, un solo número

2. La forma — cero correlación no es cero relación

3. Los grupos escondidos — la paradoja de Simpson

4. El punto palanca — un dato que gira la recta entera

5. La apertura — cuando el error crece con la escala

6. El overplotting — la nube que tapa su propia densidad

7. El checklist antes de confiar en una correlación

8. Cheat Sheet — referencia rápida para producción

Un coeficiente resume. Resumir siempre significa tirar información a la basura.

EL CUARTETO DE ANSCOMBE

En 1973 el estadístico Francis Anscombe construyó cuatro conjuntos de once puntos con el mismo promedio en x, el mismo promedio en y, la misma varianza y la misma correlación: 0,816.

Graficados, no se parecen en nada. El primero es una nube lineal con ruido. El segundo es una curva perfecta. El tercero es una recta con un solo punto desviado. El cuarto tiene todos los puntos en una única x salvo uno.

Los cuatro devuelven idéntica salida numérica. Si tu análisis se detiene en la tabla de correlaciones, los cuatro casos son el mismo caso para vos, y cuatro decisiones distintas van a salir mal.

Anscombe armó ese ejemplo para probar un punto: graficar no es un adorno del análisis, es parte del análisis.

LA FORMA

El coeficiente de Pearson mide una sola cosa: qué tan bien se ajustan tus datos a una línea recta. No mide "relación", mide "relación lineal", y esa diferencia se cobra caro.

Tomá una parábola perfecta, y = 26 menos x al cuadrado, con x simétrico alrededor de cero. La relación es determinista: conocés x, conocés y exactamente. Pearson devuelve cero.

La lectura correcta es al revés de la intuición: un r alto confirma que hay relación lineal, pero un r bajo no dice nada sobre si hay relación. Solo dice que no es una recta.

Cero correlación no es cero relación. Es cero relación lineal, que es una afirmación mucho más chica.

LOS GRUPOS ESCONDIDOS

Lo que parece una sola nube pueden ser dos poblaciones apiladas. Y cuando lo son, la tendencia del conjunto puede apuntar exactamente al revés que la de cada grupo por separado.

Eso es la paradoja de Simpson. El caso clásico: un tratamiento que funciona mejor en cada subgrupo de pacientes y peor en el total, porque los grupos difieren en tamaño y en gravedad inicial.

En un gráfico de dispersión se detecta a ojo: buscá agrupamientos, huecos y densidades desparejas. Si sospechás grupos, coloreá por la variable candidata y volvé a mirar.

Una recta sobre dos poblaciones no describe ninguna de las dos. Describe una tercera que no existe.

EL PUNTO PALANCA

Un outlier común está lejos en y: se sale de la tendencia. Un punto palanca está lejos en x, y eso lo vuelve mucho más peligroso, porque la regresión le da un peso desproporcionado.

La razón es geométrica: mínimos cuadrados minimiza la suma de errores al cuadrado, y un punto alejado en el eje x actúa literalmente como una palanca sobre la pendiente. Uno solo puede invertirle el signo.

Detectarlo es simple: ajustá con y sin ese punto y compará la pendiente. Si cambia de forma material, ese dato manda sobre tu modelo y merece una decisión explícita, no un descarte silencioso.

Antes de sacarlo, preguntate por qué está ahí. Un error de carga se corrige; un caso real que no encaja te está avisando que tu modelo es incompleto.

LA APERTURA

Si los puntos se abren en abanico a medida que avanzás en el eje x, la dispersión de tu error no es constante. El nombre técnico es heterocedasticidad, y el efecto práctico es concreto.

Tu modelo acierta con los valores chicos y falla feo con los grandes, pero el error promedio que reportás mezcla los dos regímenes en un solo número que no describe a ninguno.

Además rompe un supuesto de la regresión lineal clásica: los intervalos de confianza y los p-valores quedan mal calibrados. Salidas habituales: transformar con logaritmo, o usar errores robustos.

Un error promedio de diez no significa nada si con los valores chicos es de dos y con los grandes es de cuarenta.

EL OVERPLOTTING

Con muchos datos el gráfico de dispersión se sabotea solo: los puntos se pisan y una zona con diez mil observaciones se ve igual que una con doscientas. La forma se conserva, la densidad se pierde.

Tres arreglos, en orden de cuántos datos tenés. Transparencia (alpha entre 0,1 y 0,3) para decenas de miles. Hexbin o mapa de densidad para cientos de miles. Muestreo aleatorio solo si además necesitás velocidad.

Y un detalle de escala que se pasa por alto: fijate en qué valor arranca cada eje. Un eje truncado exagera visualmente una relación tan bien como un eje truncado exagera una barra.

Si todos tus puntos se ven, tenés pocos datos. Si tenés muchos datos y todos se ven, no estás viendo la densidad.

EL CHECKLIST

Antes de reportar cualquier correlación, pasá estas cinco preguntas. Una: ¿graficaste la nube, o solo mirás el coeficiente? Sin el gráfico no tenés con qué contestar las otras cuatro.

Dos: ¿la forma es una recta o una curva? Tres: ¿hay uno o varios grupos? Cuatro: ¿hay algún punto lejano en x que esté gobernando la pendiente? Cinco: ¿la dispersión es constante a lo largo del eje?

Si las cinco están limpias, el coeficiente que reportás describe lo que la gente va a suponer que describe. Si alguna falla, el número necesita una aclaración al lado o directamente otra métrica.

El coeficiente no es la conclusión. Es el resumen de una conclusión que ya deberías haber mirado con los ojos.

CHEAT SHEET

Graficá siempre antes de reportar un coeficiente

Pearson mide relación LINEAL, no relación

r cercano a cero con forma curva: la relación existe igual

Agrupamientos visibles: coloreá por la variable candidata

Punto lejano en x: ajustá con y sin él, compará la pendiente

Abanico que se abre: heterocedasticidad, probá logaritmo

Muchos datos: alpha 0,1 a 0,3, o hexbin

Revisá dónde arranca cada eje antes de creer la pendiente

Guardá esta guía. La próxima matriz de correlaciones la vas a leer con otros ojos.

SEGUIME EN @KEVO_IA

Todos los días comparto contenido de datos, visualización y tecnología sin vueltas.



Kevin Cáceres
Profesional de Datos e IA
linkedin.com/in/kevincaceresb